



ÉCOLE NATIONALE DES SCIENCES APPLIQUÉES DE TANGER

Conception et mise en oeuvre d'une solution décisionnelle

Data Warehouse, ETL Pentaho PDI et tableaux de bord Power BI pour l'analyse de la santé mentale des adolescents

Cycle ingénieur informatique – Module Business Intelligence / Data Warehouse

Réalisé par :
BEN ABDELLAH Mosab

Encadré par :
Pr. BADIR HASSAN

Table des matières

Introduction générale	3
1 Contexte, objectifs et architecture globale	4
1.1 Objectif fonctionnel du projet	4
1.2 Vue globale de la chaîne décisionnelle	4
1.3 Outils utilisés	5
2 Modélisation décisionnelle	6
2.1 Sources et tables de staging	6
2.2 Grain de la table de faits	7
2.3 Dimensions et mesures	8
2.4 Schéma en étoile	8
3 Processus ETL sous Pentaho Data Integration	9
3.1 Alimentation des tables de staging	9
3.2 Construction des dimensions	10
3.3 Transformation Avancée 1 : préparation qualité des faits	12
3.3.1 Logique de traitement	14
3.4 Transformation Avancée 2 : lookups des dimensions et chargement de la table de faits	14
3.4.1 Correspondances réalisées	16
3.4.2 Validation SQL	17
3.5 Problèmes rencontrés et corrections	18

4	Tableaux de bord Power BI	19
4.1	Mesures analytiques principales	19
4.2	Page 1 : vue d'ensemble	20
4.3	Page 2 : analyse par plateforme	21
4.4	Page 3 : genre et interaction sociale	22
4.5	Page 4 : risque mental et évolution temporelle	22
4.6	Page 5 : sommeil et usage numérique	23
5	Validation globale et qualité du travail	24
5.1	Cohérence du pipeline	24
5.2	Apport décisionnel	25
5.3	Points forts du projet	25
	Conclusion et synthèse	26
A	Annexes techniques	27
A.1	Requêtes de contrôle utiles	27
A.2	Principe de chargement de la table de faits	28

Introduction générale

Ce rapport présente la conception et la réalisation d'une solution décisionnelle complète autour d'un jeu de données relatif à l'usage numérique, au mode de vie scolaire et aux indicateurs de bien-être d'adolescents. Le travail couvre toute la chaîne de Business Intelligence : intégration des données sources, alimentation des tables de staging, construction des dimensions, chargement d'une table de faits, puis exploitation analytique sous Power BI.

L'objectif n'est pas seulement de produire des visualisations, mais de construire un processus décisionnel cohérent, vérifiable et justifiable. Le projet suit donc une logique de Data Warehouse : séparation entre zone de staging et modèle analytique, définition d'un grain clair, création de dimensions, contrôle qualité des données et validation par requêtes SQL.

À retenir

La valeur principale du projet réside dans la cohérence de bout en bout : chaque tableau de bord Power BI s'appuie sur une table de faits alimentée par des transformations Pentaho contrôlées et validées dans PostgreSQL.

Contexte, objectifs et architecture globale

1.1 Objectif fonctionnel du projet

Le sujet d'analyse est la santé mentale des adolescents à partir de plusieurs familles de variables : usage des réseaux sociaux, temps d'écran, sommeil, stress, anxiété, addiction, activité physique, performance académique et interaction sociale.

Définition

Le projet décisionnel consiste à transformer des données brutes issues de fichiers CSV et Excel en indicateurs exploitables dans un tableau de bord. L'utilisateur final peut suivre les niveaux moyens de stress, d'anxiété, d'addiction et de dépression selon des axes d'analyse comme le genre, l'âge, la plateforme utilisée et l'interaction sociale.

1.2 Vue globale de la chaîne décisionnelle

La solution suit une architecture classique de Business Intelligence. Pour éviter tout chevauchement visuel, le schéma ci-dessous est volontairement compact et limité aux composants essentiels.




FIGURE 1.1 – Architecture globale de la solution décisionnelle réalisée.

1.3 Outils utilisés

Outil	Rôle dans le projet
PostgreSQL	Stockage des tables staging, dimensions, tables de rejet et table de faits.
Pentaho Data Integration	Conception et exécution des transformations ETL : extraction, nettoyage, mapping, lookup et chargement.
Power BI	Connexion au modèle analytique, création des mesures DAX et visualisation des indicateurs.
pgAdmin	Exécution des requêtes de contrôle et validation des nombres de lignes.

TABLE 1.1 – *Synthèse des outils mobilisés.*

Modélisation décisionnelle

2.1 Sources et tables de staging

La première étape consiste à conserver les données brutes dans des tables de staging. Cette zone permet d'isoler l'import initial des transformations analytiques ultérieures.

Table staging	Rôle
stg_adolescents_usage	Informations d'usage : âge, genre, heures quotidiennes sur les réseaux sociaux, plateforme et temps d'écran avant sommeil.
stg_wellbeing_indicators	Indicateurs de bien-être : sommeil, stress, anxiété, addiction et label de dépression.
stg_school_lifestyle	Variables de contexte scolaire et social : performance académique, activité physique et interaction sociale.
stg_ref_platform_category	Table de référence décrivant les plateformes numériques et leur type de contenu.

TABLE 2.1 – Tables de staging créées dans PostgreSQL.




FIGURE 2.1 – Vue des tables du projet dans PostgreSQL.

2.2 Grain de la table de faits

Analyse et justification

Le grain retenu est une observation par adolescent et par date d'observation. Autrement dit, une ligne de la table de faits représente un adolescent observé à un moment donné, avec ses mesures de bien-être et d'usage numérique.

Ce grain permet d'analyser les indicateurs selon plusieurs axes : temps, âge, genre, plateforme et niveau d'interaction sociale. Il évite de mélanger des niveaux d'analyse différents dans la même table de faits.

2.3 Dimensions et mesures

Élément	Description
dim_temps	Date d’observation, jour, mois, trimestre et année.
dim_age	Âge exact et tranche d’âge.
dim_gender	Genre de l’adolescent.
dim_platform	Plateforme utilisée, famille de plateforme et type de contenu.
dim_social_interaction	Niveau d’interaction sociale : faible, moyen ou élevé.
fait_sante_mentale	Mesures numériques : stress, anxiété, addiction, sommeil, activité physique, performance académique et label de dépression.

TABLE 2.2 – Dimensions et table de faits du modèle décisionnel.

2.4 Schéma en étoile

Le modèle final est un schéma en étoile : la table de faits est au centre et les dimensions décrivent les axes d’analyse. Cette structure est adaptée aux requêtes analytiques et aux tableaux de bord.




FIGURE 2.2 – Schéma en étoile retenu pour le Data Warehouse.

À retenir

Dans ce modèle, les libellés métier comme `gender`, `platform_usage` ou `social_interaction_level` ne sont pas répétés dans la table de faits. Ils sont remplacés par des clés étrangères vers les dimensions.


Processus ETL sous Pentaho Data Integration

3.1 Alimentation des tables de staging


Les transformations initiales chargent les fichiers sources vers les tables de staging. Elles constituent la base du pipeline décisionnel.

Transformation	Rôle
TR_01_LOAD_USAGE_TO_STAGING	Chargement du fichier CSV d'usage numérique vers <code>stg_adolescents_usage</code> .
TR_02_LOAD_WELLBEING_TO_STAGING	Chargement du fichier Excel des indicateurs de bien-être vers <code>stg_wellbeing_indicators</code> .
TR_03_LOAD_SCHOOL_TO_STAGING	Chargement du fichier CSV de contexte scolaire et social vers <code>stg_school_lifestyle</code> .
TR_04_LOAD_PLATFORM_REF_TO_STAGING	Chargement du référentiel des plateformes vers <code>stg_ref_platform_category</code> .

TABLE 3.1 – Transformations d'alimentation des tables de staging.




(a) Paramétrage d'une extraction CSV.




(b) Exécution réussie d'un chargement staging.

FIGURE 3.1 – Exemple d'alimentation d'une table staging à partir d'un fichier CSV.



(a) Configuration de l'entrée Excel.



(b) Chargement réussi du fichier Excel.

FIGURE 3.2 – Chargement des indicateurs de bien-être depuis Excel.

3.2 Construction des dimensions

Les dimensions sont construites à partir des valeurs distinctes présentes dans les tables de staging. Ce choix évite de créer manuellement les membres de dimensions et garantit l'alignement avec les données réelles.




FIGURE 3.3 – Construction de dimensions simples à partir des tables de staging.




FIGURE 3.4 – Dimension âge avec âge exact et tranche d'âge.




FIGURE 3.5 – Dimension plateforme enrichie par le référentiel des catégories.

3.3 Transformation Avancée 1 : préparation qualité des faits

La transformation TR_06_QUALITY_PREPARE_FACT prépare les données propres avant le chargement final. Elle ne charge pas encore la table de faits : elle consolide, contrôle et enrichit les données dans une table intermédiaire `stg_fact_clean`.

Analyse et justification

Cette transformation a un rôle de contrôle qualité. Elle sépare les lignes valides des lignes rejetées, supprime les doublons, transforme un code technique en libellé métier et ajoute une trace du pipeline ETL. Elle rend donc le chargement final plus sûr.




FIGURE 3.6 – Transformation *TR_06_QUALITY_PREPARE_FACT* : contrôle qualité, tri, dédoublonnage, mapping et chargement propre.

3.3.1 Logique de traitement

1. extraction des données consolidées depuis les tables de staging ;
2. création d'un statut qualité et d'une raison de rejet ;
3. séparation des lignes valides et invalides ;
4. tri par id_adolescent puis suppression des doublons ;
5. mapping de depression_label vers depression_status ;
6. ajout de la constante pipeline_source pour la traçabilité ;
7. insertion dans stg_fact_clean ;
8. insertion des lignes rejetées dans etl_reject_health.

Exemple de règle de validation logique

```
1 CASE
2   WHEN age IS NULL THEN 'Age manquant'
3   WHEN stress_level NOT BETWEEN 0 AND 10 THEN 'Stress invalide'
4   WHEN daily_social_media_hours > 24 THEN 'Usage quotidien invalide'
5   ELSE 'VALID'
6 END AS quality_status
```

La table stg_fact_clean contient 1200 lignes propres. La table de rejet qualité ne contient aucune ligne dans le jeu de données final, ce qui indique que les contrôles configurés ont été validés sur les données disponibles.

3.4 Transformation Avancée 2 : lookups des dimensions et chargement de la table de faits

La transformation TR_07_LOAD_FACT_WITH_DIM_LOOKUPS réalise le passage final vers le schéma en étoile. Les valeurs métier sont remplacées par les clés des dimensions au moyen de recherches en base de données.




FIGURE 3.7 – Transformation *TR_07_LOAD_FACT_WITH_DIM_LOOKUPS* : récupération des clés de dimensions et chargement final.

3.4.1 Correspondances réalisées

Dimension	Condition de recherche	Clé retournée
dim_age	age_exact = age	id_age
dim_gender	gender = gender	id_gender
dim_platform	platform_usage = platform_usage	id_platform
dim_social_interaction	social_interaction_level = social_interaction_level	id_social_interaction

TABLE 3.2 – Lookups réalisés avant l'insertion dans la table de faits.

Requête d'extraction utilisée au début de TR_07

```

1  SELECT
2      id_adolescent,
3      ((id_adolescent - 1) % 7) + 1 AS id_temps,
4      age,
5      gender,
6      platform_usage,
7      social_interaction_level,
8      daily_social_media_hours,
9      screen_time_before_sleep,
10     sleep_hours,
11     academic_performance,
12     physical_activity,
13     stress_level,
14     anxiety_level,
15     addiction_level,
16     depression_label
17 FROM stg_fact_clean;

```




FIGURE 3.8 – Validation du chargement de la table de faits après correspondance avec les dimensions.

3.4.2 Validation SQL

Les requêtes de contrôle suivantes ont été utilisées pour confirmer que la table de faits est correctement alimentée.

Contrôles SQL finaux

```

1 SELECT COUNT(*) FROM fait_sante_mentale;
2 -- Résultat attendu : 1200
3
4 SELECT COUNT(*) AS lignes_problematiques
5 FROM fait_sante_mentale
6 WHERE id_temps IS NULL
7     OR id_age IS NULL
8     OR id_gender IS NULL
9     OR id_platform IS NULL
10    OR id_social_interaction IS NULL;
11 -- Résultat attendu : 0

```

La table `fait_sante_mentale` contient 1200 observations. Les clés étrangères vers les dimensions sont présentes, ce qui confirme la cohérence du schéma en étoile.

3.5 Problèmes rencontrés et corrections

Les difficultés rencontrées ont été traitées de manière méthodique. Elles constituent une partie importante du projet car elles montrent la capacité à diagnostiquer un pipeline décisionnel.

Problème	Cause	Correction appliquée
Lecture Excel impossible	Type de fichier configuré en ancien format Excel 97–2003 alors que le fichier était en xlsx.	Sélection du type Excel 2007 XLSX (Apache POI).
Bouton de récupération des champs indisponible	Le lien entre étapes n'était pas correctement reconnu ou les métadonnées n'étaient pas propagées.	Activation du lien et récupération des champs depuis l'étape précédente.
Erreur de TRUNCATE sur une dimension	La dimension était référencée par la table de faits via une clé étrangère.	Vidage préalable de la table de faits ou désactivation du TRUNCATE sur la dimension.
Rejets incorrects dans TR_07	Orientation du filtre ou propagation de condition mal interprétée.	Vérification SQL des clés, correction du filtre et validation finale par COUNT(*).

TABLE 3.3 – Synthèse des problèmes techniques et corrections.

Tableaux de bord Power BI

4.1 Mesures analytiques principales

Les pages Power BI reposent sur des mesures DAX simples et lisibles. Elles permettent de suivre l'état général du jeu de données et d'analyser les indicateurs par dimension.

Exemples de mesures DAX

```
1 Total Observations =  
2 COUNTRROWS('public fait_sante_mentale')  
3  
4 Stress Moyen =  
5 AVERAGE('public fait_sante_mentale'[stress_level])  
6  
7 Anxiete Moyenne =  
8 AVERAGE('public fait_sante_mentale'[anxiety_level])  
9  
10 Addiction Moyenne =  
11 AVERAGE('public fait_sante_mentale'[addiction_level])  
12  
13 Taux Depression % =  
14 AVERAGE('public fait_sante_mentale'[depression_label]) * 100  
15  
16 Score Risque Mental =  
17 DIVIDE([Stress Moyen] + [Anxiete Moyenne] + [Addiction Moyenne], 3)
```

4.2 Page 1 : vue d'ensemble

La première page présente les indicateurs globaux et deux premières lectures : répartition des observations par genre et stress moyen par plateforme.




FIGURE 4.1 – Page Power BI « Vue d'ensemble ».

Analyse et justification

Cette page joue le rôle de synthèse exécutive. Elle permet de répondre rapidement aux questions suivantes : combien d'observations sont analysées, quel est le niveau moyen de stress, d'anxiété et d'addiction, et comment les observations se répartissent par genre et plateforme.

4.3 Page 2 : analyse par plateforme

La deuxième page compare les indicateurs selon la plateforme utilisée : stress moyen, taux de dépression et addiction moyenne.




FIGURE 4.2 – Page Power BI « Analyse par plateforme ».

À retenir

Cette page est utile pour observer si certains usages numériques sont associés à des niveaux plus élevés de stress, d’addiction ou de dépression. Les segments par genre et tranche d’âge facilitent l’analyse comparative.

4.4 Page 3 : genre et interaction sociale

Cette page croise les dimensions `gender`, `platform_usage` et `social_interaction_level`. Elle permet d'identifier des écarts entre groupes.




FIGURE 4.3 – Page Power BI « Genre et interaction sociale ».

4.5 Page 4 : risque mental et évolution temporelle

La quatrième page introduit des indicateurs synthétiques : score de risque mental, taux de stress élevé et taux de dépression. Elle ajoute aussi une lecture par tranche d'âge et par trimestre/mois.



FIGURE 4.4 – Page Power BI « Risque mental et temporalité ».

4.6 Page 5 : sommeil et usage numérique

La dernière page se concentre sur le sommeil, le temps d’écran avant sommeil et l’intensité d’usage numérique.




FIGURE 4.5 – Page Power BI « Sommeil et usage numérique ».

Analyse et justification

Cette page complète l’analyse en reliant les habitudes numériques aux variables de sommeil. Elle est pertinente car le sommeil est un facteur explicatif important lorsqu’on analyse les niveaux de stress, d’anxiété ou d’addiction.

Validation globale et qualité du travail

5.1 Cohérence du pipeline

Le pipeline final est cohérent car chaque étape a une responsabilité claire.

Étape	Validation obtenue
Staging	Les fichiers sources ont été chargés dans des tables PostgreSQL séparées.
Dimensions	Les dimensions ont été créées depuis les valeurs distinctes ou les référentiels utiles.
Préparation qualité	<code>stg_fact_clean</code> contient 1200 lignes propres.
Chargement final	<code>fait_sante_mentale</code> contient 1200 observations.
Power BI	Les pages exploitent les mesures de la table de faits et les axes des dimensions.

TABLE 5.1 – Validation fonctionnelle de la chaîne décisionnelle.

5.2 Apport décisionnel

La solution permet de répondre à des questions analytiques concrètes :

- quel est le niveau moyen de stress, d'anxiété et d'addiction des adolescents ?
- quelles plateformes sont associées aux scores les plus élevés ?
- existe-t-il des différences selon le genre ou la tranche d'âge ?
- comment le sommeil et le temps d'écran avant sommeil se comportent-ils selon les groupes ?
- quels segments nécessitent une attention particulière dans l'analyse du risque mental ?

5.3 Points forts du projet

À retenir

Les points forts sont : une séparation claire staging / dimensions / faits, deux transformations ETL complexes et justifiées, des contrôles SQL de validation, des tables de rejet, des mesures DAX orientées décision et des tableaux de bord organisés par angle d'analyse.

Conclusion et synthèse

Ce projet a permis de réaliser une chaîne décisionnelle complète, depuis les fichiers sources jusqu'aux tableaux de bord Power BI. Les données ont d'abord été importées dans des tables de staging PostgreSQL, puis transformées avec Pentaho Data Integration afin de produire un modèle analytique structuré autour d'une table de faits et de plusieurs dimensions.

Les deux transformations avancées constituent le coeur technique du projet. La première assure la préparation qualité des données : filtrage, dédoublonnage, mapping métier et traçabilité. La seconde réalise les recherches dans les dimensions et charge la table de faits finale. Les validations SQL confirment que la table `fait_sante_mentale` contient 1200 observations exploitables.

Enfin, les tableaux de bord Power BI transforment le modèle en outil d'analyse. Les pages réalisées couvrent une vue globale, une analyse par plateforme, une analyse croisée genre / interaction sociale, un suivi du risque mental et une lecture centrée sur le sommeil et l'usage numérique.

La solution finale est cohérente, professionnelle et défendable : elle respecte la logique d'un Data Warehouse, documente les choix de modélisation, démontre des transformations ETL avancées et fournit des visualisations analytiques directement exploitables.

Annexes techniques

A.1 Requêtes de contrôle utiles

Contrôles PostgreSQL

```
1  -- Contrôle de la table propre
2  SELECT COUNT(*) FROM stg_fact_clean;
3
4  -- Contrôle de la table de faits
5  SELECT COUNT(*) FROM fait_sante_mentale;
6
7  -- Vérification des clés étrangères non nulles
8  SELECT COUNT(*) AS lignes_problematiques
9  FROM fait_sante_mentale
10 WHERE id_temps IS NULL
11        OR id_age IS NULL
12        OR id_gender IS NULL
13        OR id_platform IS NULL
14        OR id_social_interaction IS NULL;
```

A.2 Principe de chargement de la table de faits

Principe SQL équivalent aux lookups

```
1  SELECT
2      t.id_temps,
3      a.id_age,
4      g.id_gender,
5      p.id_platform,
6      s.id_social_interaction,
7      f.daily_social_media_hours,
8      f.screen_time_before_sleep,
9      f.sleep_hours,
10     f.academic_performance,
11     f.physical_activity,
12     f.stress_level,
13     f.anxiety_level,
14     f.addiction_level,
15     f.depression_label
16  FROM stg_fact_clean f
17  JOIN dim_temps t
18      ON t.id_temps = ((f.id_adolescent - 1) % 7) + 1
19  JOIN dim_age a
20      ON a.age_exact = f.age
21  JOIN dim_gender g
22      ON g.gender = f.gender
23  JOIN dim_platform p
24      ON p.platform_usage = f.platform_usage
25  JOIN dim_social_interaction s
26      ON s.social_interaction_level = f.social_interaction_level;
```